

1. De quoi parle l'article, en une phrase ?

Les auteurs utilisent des **capteurs RFID portables** pour mesurer, avec une **grande précision temporelle et spatiale**, les **contacts en face-à-face** dans un service de gériatrie d'un CHU, afin de **caractériser les schémas de contact** (qui voit qui, combien de temps, à quels moments du jour, etc.) et d'en déduire des **voies potentielles de transmission d'infections nosocomiales**.

2. Structure générale et questions scientifiques

L'article suit un schéma classique :

1. Introduction

- a. Importance des infections nosocomiales.
- b. Rôle des contacts proches (face-à-face, aérosols, gouttelettes) dans la transmission.
- c. Limitations des méthodes classiques (journaux de contacts, questionnaires, etc.).
- d. Apparition des **capteurs portables RFID** comme nouvel outil pour mesurer les contacts à haute résolution.
- e. Question centrale : *à quoi ressemblent vraiment les réseaux de contacts dans un service hospitalier, dans le temps et entre rôles différents ?*

2. Matériels et méthodes

- a. Description du service, des participants, des capteurs, de la définition du "contact", des agrégations temporelles.

3. Résultats

- a. Statistiques globales (nombre de contacts, durée).
- b. **Contact matrices** entre rôles (patients, infirmier·e·s, médecins, administratif).
- c. Variation temporelle (matin / après-midi / nuit, par heure).
- d. Mise en évidence de **super-contacteurs**.
- e. Similarité des contacts d'un jour à l'autre.

4. Discussion

- a. Interprétation des résultats pour le contrôle des infections.
- b. Forces et limites de la méthode RFID.
- c. Comment ces données alimentent les modèles mathématiques / épidémiologiques.

5. Conclusions et perspectives

- a. Importance des matrices de contact et de l'hétérogénéité du réseau.
- b. Besoin de plus de campagnes de mesure, d'intégration avec des données microbiologiques, etc.

3. Protocole et données : ce qu'il faut bien avoir en tête

3.1. Le cadre de l'étude

- **Lieu** : unité de gériatrie aiguë, 19 lits, dans un CHU de Lyon (~1000 lits).
- **Période** : du lundi 6 décembre 2010 (13h) au vendredi 10 décembre 2010 (14h).
→ environ 4 jours et 4 nuits.
- **Participants** :
 - 50 professionnels de santé dans le service, 31 patients admis pendant la période.
 - Données recueillies pour **46 professionnels** (92 %) et **29 patients** (94 %).
- **Organisation du travail** (important pour comprendre les pics de contacts) :
 - Deux équipes NUR (infirmier·e·s + aides-soignant·e·s) :
 - 7h–13h30, 13h30–20h.
 - 2 infirmières la nuit (20h–7h).
 - 2 médecins + 2 internes : 8h–17h.
 - Visites autorisées, mais **visiteurs non inclus** (pas de badge).

3.2. Les classes d'individus (les types de nœuds)

Les individus sont regroupés en 4 classes :

- **PAT** : patients.
- **MED** : médecins (et internes).
- **NUR** : personnel paramédical (infirmier·e·s, aides-soignant·e·s, kiné, etc.).
- **ADM** : personnel administratif.

On définit également :

- **HCW (Health Care Workers)** = MED + NUR.

En termes de *graph mining*, ce sont les **types de nœuds / partitions** pour construire une matrice de mélange (mixing matrix) entre groupes.

3.3. Le système RFID et la définition d'un "contact"

- Chaque participant porte un **badge RFID** sur la poitrine.
- Les badges échangent de petits paquets radio **quand ils sont à 1–1,5 m** l'un de l'autre, en **face-à-face** (le corps bloque l'onde, donc on privilégie le face-à-face).
- Le temps est découpé en **intervalles de 20 secondes**.
- Définition opérationnelle d'un contact :

Deux individus sont en contact pendant un intervalle de 20 secondes **si leurs capteurs échangent au moins un paquet radio dans cet intervalle**.

- Un contact se poursuit tant qu'il y a au moins un paquet échangé toutes les 20 secondes ; il est considéré interrompu si un intervalle de 20 secondes sans échange survient.

→ **Contact = arête non orientée entre deux nœuds, valable sur un intervalle de temps.**

3.4. Découpage temporel

Les auteurs analysent les données à plusieurs échelles :

- **Durée totale** de l'étude (pour les statistiques globales).
- **Jours vs nuits** :
 - Journée : 7h–20h (5 périodes diurnes).
 - Nuit : 20h–7h (4 nuits).
- **Matin / après-midi / nuit** :
 - Matin : 7h–13h30.
 - Après-midi : 13h30–20h.
 - Nuit : 20h–7h.
- **Fenêtres de 1 heure** pour voir la dynamique fine (cf. Figure 2).

4. Résultats globaux

4.1. Nombre total de contacts

- Total : **14 037 contacts** enregistrés.

- Dont **94,1 %** pendant la journée (13 206 contacts) et seulement 5,9 % la nuit (831 contacts).
- Durée cumulée de tous les contacts : **648 480 s $\approx$ 10 808 min $\approx$ 180 h.**

Idée clé : le réseau est **beaucoup plus dense le jour** que la nuit.

5. Explication des tableaux et figures

5.1. Tableau 1 – Moyenne des contacts par individu et par classe

Que montre le tableau 1 ?

- Pour chaque classe (NUR, PAT, MED, ADM), on a :
 - Nombre d'individus dans la classe.
 - **Nombre moyen de contacts par individu** (sur toute l'étude).
 - **Durée cumulée moyenne des contacts** par individu (en secondes).

Interprétation qualitative :

- **NUR et MED** ont les **plus grands nombres de contacts** et les **plus grandes durées cumulées**.
- **PAT** (patients) ont moins de contacts que NUR / MED, ce qui est cohérent avec des chambres individuelles, davantage de contacts avec les soignants qu'entre patients.
- **ADM** a relativement peu de contacts.

En termes de graphe : ce tableau donne une idée de la **distribution de degré et de poids (durée)** par type de nœud, mais seulement en moyenne par classe.

5.2. Tableau 2 – Nombre total et durée des contacts entre paires de classes

Que montre le tableau 2 ?

- C'est une **matrice (classe X, classe Y)** avec :
 - **Nombre total de contacts** entre la classe X et la classe Y, et
 - **Durée cumulée totale** de ces contacts (avec pourcentage par rapport au total général).

Les abréviations : NUR–NUR, NUR–PAT, MED–NUR, MED–PAT, etc.

Messages principaux :

- La majorité des contacts :
 - **NUR–NUR (38 % de tous les contacts).**
 - **NUR–PAT (21 %).**
- Beaucoup de contacts impliquent au moins :
 - un NUR (75,6 % des contacts),
 - un MED (28,5 %),
 - un PAT (39,2 %).
- Très peu de contacts **PAT–PAT** (patients entre eux).

Graphiquement, c'est la **matrice de mélange** entre groupes. Ça sera une base importante pour ton travail de *graph mining*.

5.3. Figure 1 – Matrices de contacts (nombre et durée)

La Figure 1 contient plusieurs matrices :

- Colonne de gauche : **nombre de contacts**.
- Colonne de droite : **durée cumulée des contacts** (en secondes).

Et sur 3 lignes :

1. **Ligne 1 :**
 - a. Élément (X,Y) = *nombre total (ou durée totale) de tous les contacts entre tous les individus de X et tous les individus de Y pendant toute l'étude.*
 - b. C'est très proche du **Tableau 2**, mais visualisé en heatmap.
2. **Ligne 2 :**
 - a. Élément (X,Y) = *nombre moyen (ou durée moyenne) de contacts d'un individu de X avec tous les individus de Y sur toute l'étude.*
 - b. On passe donc du **niveau "classe-classe"** au **niveau "individu de la classe X" vers classe Y**.
3. **Ligne 3 :**
 - a. Les valeurs de la ligne 2 sont **normalisées par la durée (en jours)** → *nombre moyen de contacts par jour ou durée moyenne par jour d'un individu de X avec Y.*

Pourquoi les matrices des lignes 2–3 sont asymétriques ?

- Parce que le nombre d'individus par classe est différent.
 - Exemple : un NUR peut voir beaucoup de patients (PAT), alors qu'un PAT ne voit que quelques NUR.
 - En moyenne, un NUR a **plus** de PAT différents qu'un PAT n'a de NUR différents.

Idée clés de la figure :

- Confirme que :
 - NUR–NUR domine en nombre et en durée.
 - NUR–PAT est aussi très important.
 - MED ont un profil de contacts différent (plus ciblé sur PAT et NUR).

En termes de graphe, ces matrices $\approx$ **adjacency matrix pondérée agrégée par type de nœud**.

5.4. Figure 2 et Tableau 3 – Dynamique horaire et jour/nuit

Tableau 3 – Contacts par période (matin, après-midi, nuit)

Tableau 3 donne :

- **Nombre de contacts** et **durée cumulée** par :
 - Matinées,
 - Après-midis,
 - Nuits,
 - - total.

Exemples (valeurs qualitatives) :

- Matins : 9 060 contacts (64,5 % des contacts de jour), durée totale 426 860 s (~65,8 %).
- Après-midis : moins de contacts et de durée que les matins.
- Nuits : très peu de contacts (831, 5,9 % du total).

Interprétation :

- **Pic de densité de contact le matin** → risque de transmission potentiellement plus élevé dans cette tranche horaire.

Figure 2 – Nombre de contacts par heure

Figure 2 :

- Graphiques montrant le **nombre de contacts par heure**, pour :
 - Tous les contacts,
 - Contacts impliquant patients,
 - Contacts impliquant HCW, etc.
- À gauche : nombre de contacts en fonction du temps écoulé depuis début de la semaine.
- À droite : courbes par jour, en fonction de l'heure (pour comparer les jours).

Messages :

- Profil temporel **similaire d'un jour à l'autre** :
 - Peu de contacts la nuit,
 - Montée du matin,
 - "Plateau" journée,
 - Rechute le soir.
- Confirme la présence de "routines" dans l'organisation des soins.

En termes de graphes temporels, on voit la **variation de densité d'arêtes au cours du temps**.

5.5. Figure 3 – Matrices de contacts par période de la journée

Figure 3 montre des **matrices (classe X, Y)** comme dans la Figure 1, mais :

- séparées en **matin, après-midi, nuit**.

Ce que ça montre :

- Le schéma global de mélange par rôle reste relativement **similaire** (NUR au centre du réseau).
- Différences plus fines :
 - Plus de **NUR-NUR** le matin,
 - Patterns un peu différents l'après-midi,
 - Nuits dominées par quelques contacts essentiels (surtout NUR, presque pas de MED/ADM).

Tu peux y voir une forme de **graphe à 3 “snapshots” temporels**, avec des motifs de contact qui gardent une structure mais changent d’intensité.

5.6. Figure 4 et Tableau 4 – Super-contacteurs

Figure 4 – Activité de chaque professionnel de santé

Figure 4 illustre, pour chaque **HCW (NUR ou MED)** :

- Nombre de **patients distincts** contactés.
- Nombre total de **contacts avec au moins un patient**.
- Durée cumulée de ces contacts.

Les auteurs mettent en évidence un petit groupe de **6 HCW** (super-contacteurs) qui représentent :

- **42,1 %** du nombre de contacts avec des patients,
- **44,3 %** de la durée cumulée des contacts avec des patients,
- alors qu’ils ne représentent que **16 %** de tous les HCW.

Ils notent aussi que :

- le nombre de contacts et la durée cumulée sont **fortement corrélés** ($r = 0,98$).

Traduction graph mining : ce sont des nœuds à **degré très élevé et poids forts**, candidats “super-spreaders”.

Tableau 4 – Détail sur les super-contacteurs

Tableau 4 donne :

- Pour tous les HCW, et pour les 6 super-contacteurs en particulier :
 - Nombre de **patients distincts** vus,
 - Nombre cumulé de contacts avec les patients,
 - Durée cumulée de ces contacts,
 - Pourcentages cumulés (quelle part du total des contacts / durées ils représentent).

Message clé :

- L'hétérogénéité est très forte : une minorité d'HCW concentre une grande part des contacts avec patients.

5.7. Données S1–S5 – Description du dataset (important pour toi)

À la fin, ils décrivent les **datasets S1 à S5**, au format **GEXF** (utilisé par Gephi) :

- Chaque **nœud** = une étiquette RFID, avec attribut :
 - $\text{role} \in \{\text{PAT}, \text{MED}, \text{NUR}, \text{ADM}\}$.
- Chaque **arête** (entre deux badges) a plusieurs attributs :
 - **Ncontacts** : nombre d'événements de contact (séquences de 20 s).
 - **cumulativeduration** : durée totale de contact.
 - **list_contacts** : liste explicite des intervalles de temps de contact.

Il y a :

- **S1–S4** : réseaux temporels par jour 1, 2, 3, 4.
- **S5** : réseau temporel avec les intervalles détaillés.

En graph mining, c'est **un réseau de contacts temporel, pondéré**, parfait pour :

- calculer degrés, centralités,
- étudier motifs temporels,
- comparer différents jours,
- générer matrices d'adjacence, etc.

6. Analyses interprétatives et conclusions des auteurs

6.1. Messages principaux

Les auteurs insistent notamment sur :

1. **Hétérogénéité forte** du nombre et de la durée des contacts :
 - a. Même au sein d'un même rôle (par ex. entre NUR), certains ont beaucoup plus de contacts.
 - b. Distribution "à queue lourde" (quelques individus très connectés).
2. **Rôle central des HCW (surtout NUR)** :
 - a. HCW, et particulièrement les NUR, accumulent le plus de contacts.

- b. Peu de contacts PAT–PAT (lié à la structure du service avec chambres individuelles).
- 3. **Existence de “super-contacteurs” :**
 - a. Un petit groupe de NUR / MED concentre une fraction très importante des contacts avec les patients.
 - b. Ces individus pourraient être des **super-propagateurs potentiels** en cas d’infection.
- 4. **Variabilité vs stabilité :**
 - a. D’un jour à l’autre, la **liste exacte des contacts** change (surtout les voisins individuels).
 - b. Mais les **statistiques globales** (matrices de contact, profils temporels) sont relativement **stables**.
- 5. **Temporalité des contacts :**
 - a. Pic de contacts le matin → potentielle sur-exposition de PAT et NUR à ce moment.
 - b. Idée : réorganiser le travail pour “lisser” les contacts entre matin et après-midi.

6.2. Implications pour le contrôle des infections

Les auteurs discutent notamment :

- **Cibler les HCW** (surtout NUR et super-contacteurs) pour :
 - formation,
 - hygiène des mains stricte,
 - vaccination,
 - port de masque, etc.
- **Réviser l’organisation des soins** lors d’épidémies/pandémies :
 - réduire les pics de densité de contacts (surtout le matin),
 - limiter les contacts inutiles ou trop longs.
- Les matrices de contact et réseaux mesurés peuvent **paramétrer des modèles de transmission** (SEIR, modèles d’hôpital, etc.) pour simuler :
 - différents agents pathogènes (grippe, rotavirus, S. aureus, etc.),
 - différents scénarios de contrôle (vaccination ciblée, isolations, modifications de planning).

6.3. Limites reconnues

Les auteurs sont assez honnêtes sur les limites :

- **Contact = proximité (1–1,5 m) face-à-face**
→ ne mesure pas directement :
 - le **contact physique**,
 - la contamination par surfaces (fomites),
 - les flux d'air complexes.
- Ils **n'ont pas de données microbiologiques couplées** :
 - Ils mesurent des **contacts potentiels**, pas des transmissions effectives.
- **Visiteurs non inclus** (pas de badges) :
 - Une source potentielle de transmission manque dans le réseau.
- **Possibles biais de comportement** dus au port de badge (effet Hawthorne) :
 - Ils pensent que c'est limité, mais ne peuvent pas l'exclure.

7. Lien avec ton cours de Graph Mining (pour la suite)

Sans entrer encore dans les détails de l'étape 2, tu peux déjà voir :

- **Graphe** :
 - Nœuds = individus (RFID).
 - Arêtes = contacts (existence + poids = nombre d'intervalles ou durée).
 - Attributs : rôle du nœud, jours, listes d'intervalles de contact.
- **Ce qu'ils ont déjà exploité** :
 - **Matricess de mélange** entre classes (agrégation par rôle).
 - **Degré / intensité de contact** des nœuds (super-contacteurs).
 - **Dynamique temporelle** simple (courbes par heure, similarité d'un jour à l'autre).
- **Ce qu'on pourra encore explorer avec des outils de graph mining** :
 - distributions de degré / de poids plus détaillées (loi de puissance, etc.),
 - centralités (betweenness, eigenvector, etc.) pour les HCW et PAT,
 - motifs temporels (séquences PAT–NUR–PAT, etc.),
 - communautés / modules (groupes d'individus plus fortement interconnectés),
 - robustesse des conclusions quand on change l'échelle temporelle ou la pondération,
 - comparaison des réseaux jour 1, 2, 3, 4 (similarité structurelle).



Synthèse : les 5 analyses les plus puissantes à mener

1. **Degree + Power-law + hétérogénéité**
→ confirmer objectivement la notion de super-contacteurs.
2. **Centralités avancées**
→ voir si les super-contacteurs le sont aussi selon betweenness, eigenvector, PageRank.
3. **Null models (configuration model)**
→ tester si les patterns NUR–PAT sont structurels ou attendus.
4. **Communautés + stabilité temporelle**
→ valider/invalider la conclusion “patterns similaires chaque jour”.
5. **Simulations d'épidémies SI/SIS sur réseau temporel**
→ confirmer si la structure mesurée implique réellement une forte vulnérabilité.

0. Contexte rapide et données

Données : jeux S1–S5 (réseau de contacts RFID dans un service de gériatrie, format GEXF, rôle de chaque nœud = PAT / NUR / MED / ADM) .

Cours : tu as tout l'arsenal classique de **structure de réseau, modèles aléatoires, communautés, random walks, processus épidémiques** .

1. Objectif scientifique + hypothèses à tester

Tu peux formuler ton projet comme :

“Évaluer, à l'aide des outils de graph mining, si les conclusions de Voirin et al. (2013) sur l'hétérogénéité des contacts, le rôle central des soignants et la stabilité des schémas de contact sont robustes, et si d'autres structures cachées émergent.”

Hypothèses possibles :

- **H1 – Super-contacteurs :**
L'hétérogénéité (quelques soignants concentrent >40 % des contacts avec les patients) se traduit par :
 - une **distribution à queue lourde** des degrés/forces,
 - et des valeurs extrêmes de centralité.

- **H2 – Rôle central des NUR/MED :**
NUR et MED constituent un **core** du réseau, les PAT un **périphérique** (core–periphery).
- **H3 – Stabilité des patterns :**
La structure globale (matrices de contacts, communautés) est **stable d’un jour à l’autre**, mais les voisins individuels changent (ils annoncent : “schémas qualitativement similaires d’un jour à l’autre”).
- **H4 – Structure modulaire :**
Le service n’est pas juste “un gros bloc” mais possède des **communautés** (clusters de patients + soignants).
- **H5 – Risque épidémique :**
Un pathogène introduit chez un super-contacteur diffuse plus vite / plus largement que chez un individu “moyen” (processus SI/SIS sur le réseau temporel).

2. Préparation des données

Étapes concrètes

1. **Charger les fichiers GEXF** (S1–S4 : par jour ; S5 : temporel détaillé).
 - a. Outils : NetworkX ou iGraph, comme conseillé dans le cours .
2. **Représentation du graphe**
 - a. Nœuds : individus, attribut role $\in \{\text{PAT, NUR, MED, ADM}\}$.
 - b. Arêtes : contacts entre deux individus, avec :
 - i. Ncontacts / weight = nombre total d’événements,
 - ii. duration = durée cumulée,
 - iii. pour S5, liste d’intervalle de contact (graphe temporel).
3. **Construire :**
 - a. Un graphe **agrégé total** (toute la période).
 - b. Quatre graphes **par jour** (S1–S4).
 - c. Éventuellement des graphes **par tranche horaire** (matin / après-midi / nuit).

 À documenter dans le rapport dans une section “Data & Preprocessing”.

3. Analyse 1 – Degré, force, hétérogénéité (H1)

→ Cours : IV.B – Degree distribution + D. Power-law distributions

3.1. Mesures

Pour chaque nœud :

- **Degré** : nombre de voisins.
- **Force** (degree pondéré) : somme des durées de contacts ou du nombre de 20s-intervals.

3.2. Analyses

- Tracer :
 - Histogrammes du degré et de la force (log-log si possible).
 - Courbes CCDF ($P(K \geq k)$) pour voir les queues lourdes.
- Estimer si une **loi de puissance** est plausible (méthode maximum likelihood / Clauset-Newman-Shalizi, comme dans ta section sur les power-laws).

3.3. Figures / tableaux

- **Figure A1** : distribution du degré (tous les nœuds).
- **Figure A2** : distribution de la force.
- **Tableau A1** : moyenne, variance, quantiles, max (comparaison par rôle : PAT vs NUR vs MED vs ADM).

🔗 **Lien avec l'article** : vérifier si les “super-contacteurs” sont des outliers extrêmes par rapport à la distribution attendue.

4. Analyse 2 – Centralités (H1, H2)

→ Cours : IV.E – Centrality (closeness, betweenness, Katz, PageRank)

4.1. Ce que tu calcules

Pour chaque nœud (surtout HCW) :

- **Degree centrality**

- **Betweenness centrality**
- **Closeness**
- Optionnel : **eigenvector** ou **Katz** / PageRank (sur graphe pondéré).

4.2. Analyses

- Comparer les **super-contacteurs de l'article** (top 6 en nombre de contacts) aux **top-n selon betweenness / eigenvector**.
- Vérifier si les mêmes individus sortent ou pas.

4.3. Figures / tableaux

- **Figure B1** : scatter plot force vs betweenness, avec couleur = rôle (PAT/NUR/MED).
- **Tableau B1** : top 10 nœuds pour chaque centralité, avec leur rôle.

🎯 Objectif :

- confirmer que ces 6 personnes sont réellement **structuralement centrales**,
- ou montrer que d'autres individus sont aussi très critiques (nuancer les conclusions).

5. Analyse 3 – Modèles nuls et motifs (H2)

→ Cours :

- **V.A-B – ER & Configuration model**
- **V.C – Network motifs**

5.1. Modèle nul (Configuration model)

- Construire un **graphe aléatoire** sur les mêmes nœuds, avec le **même degré** pour chaque nœud (configuration model).
- Calculer :
 - Matrice de contact entre rôles (PAT/NUR/MED/ADM) sur ce graphe randomisé.
 - Distributions de triangles, etc.

Comparer à la matrice de contact réelle (comme Fig. 1 et 3 de l'article).

☞ Si la surreprésentation des contacts NUR–PAT est bien au-delà de ce qu’explique la seule séquence de degrés → structure non triviale.

5.2. Motifs

- Choisir quelques motifs simples :
 - PAT–NUR–PAT,
 - PAT–NUR–MED,
 - triangles NUR–NUR–PAT, etc.
- Comparer leur fréquence à celle du modèle nul, via **Z-score**, exactement comme présenté pour les motifs dans ton cours).

Figures

- **Figure C1** : comparaison des matrices de contacts “réel vs configuration model”.
- **Figure C2** : barplot des Z-scores de quelques motifs.

🎯 Objectif :

- tester si la structure “NUR au centre + chaînes PAT–NUR–PAT” est **statistiquement significative**.

6. Analyse 4 – Communautés & core–periphery (H2, H4)

→ Cours :

- VI – Community detection (modularity, Louvain)
- IX.D – Core–periphery structure

6.1. Détection de communautés

- Appliquer **Louvain** (ou autre méthode) sur le graphe agrégé.
- Calculer :
 - **modularité**,
 - nombre de communautés,
 - distribution des rôles dans chaque communauté (ex : communauté = 1 médecin + 4 infirmiers + 6 patients).

6.2. Comparaison avec les rôles

- Est-ce que les communautés suivent :
 - les classes fonctionnelles (NUR/MED/PAT),
 - la structure organisationnelle (sous-équipe de soignants),
 - les jours / shifts ?

6.3. Core–periphery

- Utiliser une méthode de détection core–periphery (du cours) sur le graphe agrégé.
- Vérifier si :
 - le core est majoritairement NUR/MED,
 - les PAT sont surtout en périphérie.

Figures

- **Figure D1** : visualisation du graphe avec couleurs = communautés.
- **Tableau D1** : composition des communautés (nombre de PAT/NUR/MED/ADM).
- **Figure D2** : core vs periphery, histogramme des rôles dans chaque.

🔗 **Objectif** : quantifier la structure que l'article décrit qualitativement.

7. Analyse 5 – Dimension temporelle et stabilité (H3)

→ Cours : **Temporal networks + Dynamics & time-scales**

7.1. Densité horaire & journalière

- Reproduire / détailler Fig. 2 de l'article : nombre de contacts par heure, par type de rôles .
- Tu peux enrichir en traçant :
 - diamètre / moyenne des plus courts chemins par heure,
 - nombre de composantes connexes par heure.

7.2. Stabilité du voisinage (jour à jour)

Pour chaque individu i :

- ensemble de voisins à J1 : $N_1(i)$
- à J2 : $N_2(i)$
- **similarité de Jaccard** : $|N_1(i) \cap N_2(i)| / |N_1(i) \cup N_2(i)|$

Calculer :

- moyenne des similarités J1–J2, J2–J3, J3–J4, par rôle.
- distribution (boxplots).

☞ Cela teste directement la phrase “schémas qualitativement similaires d’un jour à l’autre” mais de façon quantitative.

7.3. Stabilité des communautés

- Appliquer Louvain séparément sur S1, S2, S3, S4.
- Comparer les partitions via ARI/NMI (mesures de similarité de partitions).

Figures

- **Figure E1** : Jaccard moyen des voisins par rôle, J1–J2, etc.
- **Figure E2** : heatmap NMI(communautés jour a, jour b).

🎯 **Objectif** : confirmer ou nuancer l’idée que le réseau est “stable dans sa structure”.

8. Analyse 6 – Processus épidémiques sur le réseau (H5)

→ Cours : **X – Epidemic processes (SI, SIS)**, rôle de $\langle k^2 \rangle / \langle k \rangle$ sur les seuils épidémiques

8.1. Protocoles de simulation (réseau temporel S5)

- Modèle simple SI ou SIS sur **réseau temporel** :
 - infection possible lorsqu’un contact est actif,
 - probabilité de transmission par contact p (ex : 0.02, 0.05, etc.),
 - éventuellement, guérison (SIS) avec probabilité μ .

8.2. Expériences

- Cas 1 : infection initiale = patient “lambda”.
- Cas 2 : infection initiale = super-contacteur (comme défini dans l’article).
- Pour chaque cas :
 - nombre final d’infectés,
 - vitesse de propagation (temps pour atteindre X % des individus),
 - nombre de patients infectés.

Figures

- **Figure F1** : courbes nombre d’infectés(t) pour différentes seeds.
- **Tableau F1** : comparaison des résultats (patient vs super-contacteur vs NUR random).

🎯 Objectif :

- vérifier si, **dans le réseau réel**, les super-contacteurs ont bien un rôle d’amplification du risque,
- relier à la littérature sur l’impact de $\langle k^2 \rangle / \langle k \rangle$ et des hubs dans la propagation .

9. Structure finale possible de ton rapport / travail

Tu peux structurer ton rapport comme ceci :

1. Introduction

- a. Contexte infections nosocomiales + article Voirin et al.
- b. Objectifs et hypothèses (H1–H5).

2. Données et méthode

- a. Description du service, capteurs, jeux S1–S5 (en t’appuyant sur l’article).
- b. Modélisation en graphe (nœuds, arêtes, pondération, temps).

3. Résultats structuraux statiques

- a. Degré, power-laws, super-contacteurs.
- b. Centralités, core–periphery, communautés.
- c. Comparaison avec modèles nuls et motifs.

4. Résultats temporels

- a. Densité horaire, comparaisons jour à jour.
- b. Stabilité des voisins, des communautés.

5. Résultats dynamiques (épidémies)

- a. Simulations SI/SIS, impact des super-contacteurs.

6. Discussion

- a. En quoi tes analyses **confirment**, **précisent** ou **contredisent** l'article.
- b. Limites (taille petite, biais de mesure, hypothèses de modèles).
- c. Pistes futures (autres modèles, d'autres services, etc.).

7. Conclusion

ARTICLE 1:

✦ TEXTE RÉDIGÉ (Style Rapport – Analyse 1)

Analyse 1 — Structure de degré et hétérogénéité des contacts

Dans cette première analyse, notre objectif est d'examiner la structure élémentaire du réseau de contacts obtenu par les capteurs RFID, en nous concentrant sur la distribution des degrés et des degrés pondérés. Cette approche constitue la base de toute lecture structurale d'un réseau humain et permet d'identifier les signatures d'hétérogénéité susceptibles d'expliquer l'importance disproportionnée de certains individus dans les dynamiques de transmission. Le degré d'un nœud est défini comme le nombre d'individus distincts avec lesquels l'acteur étudié a été en contact au moins une fois durant la période d'observation. Dans un contexte hospitalier, cette mesure capture la diversité des interactions : un patient aura typiquement un degré modeste, tandis qu'un membre du personnel soignant, en particulier infirmier, interagira avec un nombre nettement plus élevé d'acteurs.

La construction du graphe repose sur un agrégat temporel couvrant l'ensemble de la période observée. Chaque nœud représente une personne équipée d'un badge RFID et comporte un attribut indiquant son rôle institutionnel (patient, infirmier, médecin ou

personnel administratif). Une arête non orientée est ajoutée entre deux nœuds dès lors qu'au moins un contact de vingt secondes ou plus a été détecté entre eux. Cette première représentation binaire est déjà informative, mais elle ne permet pas d'appréhender l'intensité des interactions. Pour capturer cette dimension, nous considérons également une matrice pondérée dans laquelle le poids w_{ij} de chaque arête correspond à la durée cumulée des contacts entre i et j . Le degré pondéré, ou strength, $s_i = \sum_j w_{ij}$, mesure ainsi le temps total passé par un individu en interaction directe, révélant des formes de centralité invisibles dans la simple structure non pondérée.

L'examen global des degrés met en évidence une forte asymétrie, caractéristique de réseaux humains structurés par rôles sociaux différenciés. La moyenne des degrés, égale à $2M/N$ selon le lemme de la poignée de main, est relativement peu représentative de la réalité individuelle : la majorité des nœuds présente une valeur inférieure à cette moyenne, tandis qu'une minorité concentre les valeurs les plus élevées. L'analyse de la distribution empirique confirme cette observation : l'histogramme des degrés présente une queue longue, et les représentations semi-logarithmiques ou log-log suggèrent une hétérogénéité marquée. Les infirmiers, en particulier, occupent des positions nettement plus connectées que les patients, ce qui reflète une organisation du travail où les soignants constituent les principaux vecteurs d'interactions entre groupes.

Cette hétérogénéité s'amplifie encore lorsque l'on considère les degrés pondérés. Plusieurs soignants montrent des valeurs de strength très élevées, traduisant un temps de contact cumulé particulièrement important. En termes de structure réseau, ces acteurs se comportent comme des hubs : non seulement ils interagissent avec un grand nombre d'individus, mais leur présence prolongée en face-à-face accroît leur potentiel de transmission. Ce phénomène explique naturellement le paradoxe de l'ami, par lequel le degré moyen d'un voisin d'un individu est supérieur au degré moyen du réseau. Dans le cas présent, ce mécanisme accentue le rôle des soignants dans l'architecture du réseau, puisqu'ils apparaissent plus fréquemment en tant que voisins que les patients, simplement en raison de leur nombre élevé de connexions.

L'ensemble de ces résultats suggère que le réseau hospitalier étudié possède une structure fortement hétérogène, dominée par quelques individus très connectés et très actifs en termes de durée de contact. Cette configuration constitue un terrain propice à l'émergence de super-contacteurs, dont l'identification repose déjà sur cette première analyse structurale. Les étapes suivantes viseront à confirmer et raffiner cette lecture à l'aide de mesures de centralité plus sophistiquées et de modèles nuls permettant de distinguer effets organisationnels et véritables propriétés structurelles du réseau.