

Analyse du réseau de contacts du Malawi

Application des concepts du cours et comparaison des distributions

1 Introduction

Ce rapport présente une analyse détaillée du réseau de contacts collecté dans un village rural du Malawi à l'aide de capteurs de proximité. Ces données, enregistrées à haute résolution temporelle, permettent de reconstruire le réseau social réel d'une communauté et d'en étudier la structure interne, la dynamique sociale et les mécanismes potentiels de diffusion d'une infection.

L'objectif de ce travail est :

- comprendre la structure sociale sous-jacente du village et identifier les acteurs clés ;
- comparer nos observations quantitatives aux conclusions de l'article scientifique original.

2 Description du dataset

Les données analysées dans ce rapport proviennent d'une étude de terrain menée dans le village rural de **Mdoliro**, Malawi, où les habitants ont porté des capteurs de proximité de type RFID. Ces capteurs enregistrent automatiquement les contacts entre individus, à une résolution temporelle (secondes).

Le fichier brut disponible (`tnet_malawi_pilot.csv`) contient les colonnes suivantes :

- **id1** : identifiant du premier individu en contact ;
- **id2** : identifiant du second individu ;
- **day** : jour de la collecte (période d'observation de plusieurs jours) ;
- **contact_time** : durée du contact enregistré ;
- une colonne "*Unnamed: 0*" issue de l'export, supprimée lors du prétraitement.

Chaque ligne correspond donc à un *événement de contact*. Lorsque deux personnes interagissent plusieurs fois, plusieurs lignes peuvent apparaître.

Nettoyage appliqué

Afin de reconstituer un réseau cohérent et comparable à celui utilisé dans l'article :

1. suppression des lignes dont le **contact_time** est égal à 0 ;

2. agrégation des interactions entre une même paire d'individus (somme des durées cumulées) ;

Après agrégation, le graphe contient :

- **86 nœuds** ;
- **347 arêtes** ;
- Le graphe obtenu est composé de deux composantes connexes : une composante géante de 84 nœuds et une composante mineure de 2 nœuds isolés.

3 Structure générale du réseau

3.1 Construction du graphe (non pondéré)




Figure 1: Réseau de contacts du Malawi

Le réseau observé est presque entièrement connecté, ce qui suggère une communauté socialement soudée. Le **degré moyen** est de **8.07**, indiquant un niveau notable de connectivité, tandis que le **degré maximal** atteint **31**, révélant l'existence de personnes très actives socialement.

Le **coefficient de clustering**, égal à **0.5269**, constitue l'un des résultats les plus marquants. Il montre une

densité exceptionnelle de triangles, traduisant des sous-groupes fortement cohésifs, sans doute liés aux ménages.

La **distance moyenne** de **2.6153** et le **diamètre** limité à **5** indiquent une structure compact. Malgré la présence de clusters internes, les individus restent proches les uns des autres, en moyenne à deux ou trois intermédiaires.

Le réseau présente ainsi les caractéristiques typiques d'un small-world : forte densité locale et communication rapide à l'échelle globale.

4 Analyse des centralités

4.1 Betweenness Centrality

La **betweenness centrality** met en évidence les individus jouant un rôle d'intermédiaire entre différentes parties du réseau. Le nœud **16** se distingue particulièrement avec une valeur de **0.3197**, nettement supérieure à celles des nœuds 81 et 74.

Il occupe une position stratégique : de nombreux plus courts chemins reliant des individus distincts passent par lui. Son rôle de pont contribue fortement à la cohésion du réseau, rendant sa position structurellement essentielle.

4.2 Eigenvector Centrality

La **eigenvector centrality** identifie les individus appartenant au cœur des structures les plus connectées. Les nœuds **70**, **54**, **15**, **63** et **48** obtiennent les valeurs les plus élevées (par exemple **0.5464** pour le nœud 70).

Ils forment un noyau central où l'influence sociale est renforcée par la proximité avec d'autres individus centraux. Ces nœuds jouent un rôle d'ancrage dans la structure interne du village.

4.3 PageRank

Le **PageRank** met en évidence l'importance dynamique des individus. Le nœud **16** présente une valeur élevée de **0.02835**, suivi des nœuds **70** (**0.02410**) et **54** (**0.02026**).

Ces mesures confirment l'existence de deux types d'acteurs clés : des intermédiaires structurants et un noyau dense d'individus influents.

4.4 Closeness Centrality

La **closeness centrality** renseigne sur la proximité moyenne d'un individu avec le reste du réseau. Le nœud **16** présente une valeur de **0.5845**, ce qui confirme sa position centrale. Les nœuds **81** (**0.5389**), **74** (**0.5061**) et **86** suivent avec des valeurs élevées.

La superposition d'une **betweenness** élevée et d'une **closeness** élevée confirme que le nœud 16 joue simultanément le rôle d'intermédiaire et de centre géométrique du réseau.

5 Comparaison avec des modèles aléatoires

5.1 Modèle Erdős–Rényi

Le modèle **Erdős–Rényi** permet de mesurer dans quelle mesure la structure observée pourrait émerger du hasard. Le **clustering moyen** des graphes ER atteint seulement **0.0976**, loin du clustering réel **0.5269**. La **variance des degrés** y est également beaucoup plus faible (**7.27** contre **26.13**).

La **distance moyenne** observée dans les graphes ER est de **2.3389**, légèrement inférieure à celle du réseau réel, ce qui reflète l'absence de structure interne.

Enfin, la **modularity** obtenue dans ER est d'environ **0.292**, très éloignée de la valeur réelle **0.893**. Cela montre que le réseau ne peut absolument pas être assimilé à un graphe aléatoire simple.

5.2 Configuration Model

Le **Configuration Model**, qui conserve la distribution exacte des degrés, ne parvient pas davantage à reproduire les caractéristiques du réseau réel. Le **clustering** n'y atteint que **0.1393**, et la **modularity** seulement **0.3013**.

Bien que la **distance moyenne** simulée (**2.4256**) soit proche de celle du réseau réel, ces modèles restent incapables de recréer l'intensité des communautés. Cela montre que la structure observée ne provient pas des degrés, mais d'une organisation sociale réelle et forte.

6 Marche aléatoire

La marche aléatoire, qui mesure la dynamique de visite des nœuds, met en évidence les individus les plus susceptibles d'être atteints lors d'un parcours au hasard. Le nœud **16** obtient une proportion de visites de **0.046**, suivi par les nœuds 81, 86, 74 et 70.

Cela confirme que certaines personnes concentrent naturellement une part importante de la dynamique sociale, en raison de leur positionnement structurel.

7 Profil temporel des interactions

L'analyse des contacts par heure met en évidence des variations significatives de l'activité sociale. Les heures **30** et **31** présentent des pics importants, avec respectivement **9217** et **9902** contacts.

Ces fluctuations suggèrent l'existence de routines collectives ou de moments de rassemblement intense, montrant que le réseau n'est pas seulement structuré spatialement, mais également temporellement.

8 Interprétation

L'analyse confirme l'hypothèse centrale de l'article : les ménages constituent des unités sociales fortement

cohésives. Le **clustering élevé (0.5269)** et la **modularity exceptionnelle (0.893)** montrent que les interactions sont intensément concentrées à l'intérieur de groupes soudés.

Cependant, nos résultats révèlent un aspect que l'article ne développe pas entièrement. Les mesures de centralité, notamment la **betweenness (0.3197)** et la **closeness (0.5845)** du nœud 16, montrent que certains individus jouent un rôle déterminant dans la connectivité entre ménages. Le réseau ne se limite pas à des foyers séparés : il est relié par un petit nombre de personnes-pivots essentielles pour la cohésion globale.

L'identification d'un noyau interne, via l'eigenvector centrality, montre que la structure sociale ne repose pas uniquement sur les familles. Certains individus occupent des positions stabilisatrices au sein des clusters.

Enfin, l'analyse temporelle révèle des pics d'activité collective, soulignant une organisation sociale qui suit des rythmes réguliers.

Dans l'ensemble, le village apparaît comme un système social structuré par des clusters familiaux forts mais maintenu cohérent par quelques individus clés qui assurent la connectivité entre ces clusters. Ces résultats confirment et enrichissent les observations de l'article.

9 Analyse communautaire

9.1 via l'algorithme de Louvain

Nous appliquons l'algorithme de Louvain sur deux versions du réseau : (i) le graphe non pondéré G , et (ii) le graphe pondéré G_w où le poids représente la durée cumulée des interactions.

Les résultats obtenus sont les suivants :

- **Graphe non pondéré** : 10 communautés, modularité = **0.511**.
- **Graphe pondéré** : 22 communautés, modularité = **0.893**.

La modularité pondérée exceptionnellement élevée confirme que les interactions sont très concentrées au sein des ménages, avec relativement peu de liens entre foyers. L'algorithme détecte donc un nombre important de communautés lorsqu'il tient compte des poids.

Stabilité du Louvain

Afin d'évaluer la robustesse de l'algorithme, nous répétons Louvain sur 20 exécutions indépendantes. Les résultats montrent que :

- le graphe non pondéré oscille entre **9** et **10** communautés ;
- le graphe pondéré est **parfaitement stable** : **22 communautés** à chaque exécution.

Cette stabilité accrue dans le cas pondéré s'explique par la présence de poids très contrastés entre contacts intra- et inter-ménages, qui rigidifient la structure communautaire.




Figure 2: Stabilité du nombre de communautés détectées par Louvain

Comparaison avec l'article

L'article de référence rapporte, pour le réseau complet (86 nœuds et 355 arêtes) :

- **8 communautés** dans le réseau non pondéré (modularité = **0.48**),
- **13 communautés** dans le réseau pondéré (modularité = **0.75**).

Nos résultats diffèrent de manière notable :

1. Nous observons **10 communautés** (non pondéré) et **22 communautés** (pondéré), soit davantage que les **8** et **13** communautés rapportées dans l'étude.
2. Notre modularité pondérée (**0.893**) est beaucoup plus élevée que celle de l'article (**0.75**), ce qui reflète une segmentation communautaire plus forte.
3. Ces écarts s'expliquent par des différences structurelles dans le dataset utilisé : après agrégation des contacts, notre version contient **347 arêtes** et non 355, ce qui réduit la connectivité inter-ménages et accentue artificiellement les frontières entre communautés.

Malgré ces divergences quantitatives, les deux analyses convergent vers la même conclusion qualitative : **les ménages constituent les unités communautaires dominantes du réseau**, et la modularité élevée indique une forte cohésion interne et des interactions limitées entre groupes.

9.2 Méthodes basées sur des marches aléatoires

Les méthodes fondées sur des marches aléatoires exploitent la manière dont un flux (d'information, d'individus) se déplace spontanément dans le réseau. Elles sont particulièrement pertinentes pour analyser la

cohésion interne des groupes et la dynamique sociale du village.

Nous appliquons ici deux méthodes classiques : **Infomap** et **Walktrap**.

Infomap : partitionnement basé sur le flux d'information

Infomap repose sur le *Map Equation*, qui mesure la capacité à compresser la description d'une marche aléatoire sur le réseau. Si une marche aléatoire tend à rester longtemps dans une même communauté, alors la structure possède une organisation modulaire cohérente.

L'exécution d'Infomap sur le réseau Malawi donne :

- 10 communautés détectées,
- tailles : [37, 13, 8, 4, 6, 5, 5, 3, 3, 2].

Cette partition montre une structure où un grand module central (37 individus) coexiste avec plusieurs petits ensembles fortement cohésifs. Cela suggère que le village ne se compose pas uniquement de ménages isolés, mais d'agrégats sociaux plus larges, où certains clusters regroupent plusieurs foyers.

Walktrap : communautés détectées via marches courtes

Walktrap s'appuie sur l'idée que des marches aléatoires courtes restent piégées dans les communautés. La méthode calcule des distances entre nœuds en comparant leurs signatures de marche aléatoire.

L'application de Walktrap donne :

- 11 communautés détectées,
- tailles : [17, 3, 22, 3, 12, 6, 5, 8, 5, 3, 2].

Walktrap identifie des modules légèrement plus nombreux qu'Infomap, avec notamment deux communautés moyennes (17 et 22 membres) et plusieurs petits groupes correspondant à des ménages denses ou micro-communautés locales.

Cette structuration, basée sur la proximité dynamique entre individus, reflète fidèlement l'organisation sociale du village : des foyers fortement cohésifs reliés entre eux par des liens plus faibles, exactement comme décrit dans l'article original.

Comparaison des méthodes basées sur la marche aléatoire

Infomap et Walktrap produisent des résultats cohérents mais complémentaires :

- Infomap met en évidence un **macro-groupe dominant** de 37 individus, signe d'un flux social très concentré autour de certains clusters.
- Walktrap révèle une structure **méso-échelle** plus détaillée, avec 11 communautés dont plusieurs de taille moyenne (12 à 22 individus).

Ces deux méthodes contrastent avec Louvain pondéré, qui segmente davantage le réseau (22 communautés), car Louvain exploite fortement les variations de poids.

Les méthodes basées sur la marche aléatoire montrent au contraire que, d'un point de vue dynamique,

- les ménages ne sont pas des modules isolés,
- plusieurs d'entre eux fonctionnent comme des blocs sociaux plus larges,
- le village possède une structure communautaire hiérarchique, allant du ménage vers des communautés agrégées.

Ainsi, Infomap et Walktrap révèlent des caractéristiques sociales clés du réseau : la coexistence d'un noyau central très interconnecté et d'une périphérie composée de petits groupes familiaux.

10 Spectre du Laplacien et dynamique de consensus

L'analyse spectrale constitue un outil fondamental pour comprendre la structure interne d'un réseau. Elle permet d'identifier les composantes connexes, de quantifier la cohésion des communautés et d'étudier la dynamique de propagation ou de synchronisation sur le graphe. Dans cette section, nous analysons le réseau Malawi à travers trois approches complémentaires : le **spectral clustering**, le **spectre du Laplacien normalisé** et la **dynamique de consensus** $\dot{x} = -Lx$.

10.1 Spectral clustering

Nous appliquons un spectral clustering en fixant le nombre de communautés à $k = 10$, valeur obtenue via Louvain non pondéré.

Le résultat obtenu est le suivant :

10 communautés avec tailles [24, 16, 14, 8, 6, 5, 5, 3, 3, 2].

Ces tailles montrent une structure modulaire cohérente : quelques communautés de taille moyenne dominent la décomposition, accompagnées de plusieurs groupes plus petits, probablement liés à des ménages ou sous-ménages.

10.2 Valeurs propres du Laplacien normalisé

Le calcul des dix plus petites valeurs propres du Laplacien normalisé donne :

$$\lambda = \begin{bmatrix} 0.000000 \\ 0.000000 \\ 0.067425 \\ 0.132788 \\ 0.147327 \\ 0.184823 \\ 0.232372 \\ 0.298524 \\ 0.312749 \\ 0.331314 \end{bmatrix}.$$

Ces résultats permettent plusieurs observations majeures :

1. **Présence de deux valeurs propres nulles.** Selon le théorème spectral du Laplacien, la multiplicité de $\lambda_1 = 0$ correspond au nombre de composantes connexes. La présence de deux valeurs nulles indique que le réseau Malawi contient exactement deux composantes connexes.

Cela correspond à l'existence de deux individus totalement isolés du reste de la population.

2. **Valeurs propres faibles ($\lambda_2, \lambda_3, \dots$).** Les valeurs proches de zéro (0.067, 0.133, 0.147) indiquent une séparation nette entre les ménages. Cela révèle une structure modulaire très forte : densité interne élevée dans les communautés, faible connectivité entre communautés.

En comparaison, l'article du Malawi rapporte également une forte modularité et une structure fortement contrainte par les ménages. L'analyse spectrale confirme rigoureusement ces observations.

10.3 Dynamique de consensus

Nous simulons la dynamique continue :

$$\dot{x} = -Lx,$$

où chaque nœud possède un état initial aléatoire. Cette dynamique modélise la convergence d'opinions, d'informations ou de comportements.




Figure 3: Dynamique de consensus sur le réseau Malawi.

L'interprétation est la suivante :

- Les courbes convergent rapidement à l'intérieur d'un ménage, ce qui reflète une **forte cohésion locale**.
- La convergence globale est beaucoup plus lente : cela correspond au fait que les liens inter-ménages sont faibles.
- Le plateau final correspond à un consensus global stable.

Ce phénomène illustre la **séparation d'échelles** décrite au Chapitre 6 : les clusters internes se stabilisent très vite, tandis que l'harmonisation entre clusters est graduelle.

11 Analyse multi-échelle : γ -modularity

L'approche γ -modularity permet d'étudier la structure communautaire du réseau à différentes échelles de résolution. Elle repose sur une généralisation de la modularité classique où le paramètre γ contrôle le degré de sensibilité aux petites ou grandes communautés. Un γ faible favorise des communautés larges, tandis qu'un γ élevé tend à subdiviser le réseau en modules plus fins.

Nous appliquons l'algorithme de Louvain pondéré pour plusieurs valeurs de $\gamma \in \{0.5, 1.0, 1.5, 2.0, 3.0\}$. Les résultats obtenus sont résumés ci-dessous :

- $\gamma = 0.5$: 26 communautés, $Q = 0.8860$
- $\gamma = 1.0$: 22 communautés, $Q = 0.8930$ (maximum observé)
- $\gamma = 1.5$: 23 communautés, $Q = 0.8903$
- $\gamma = 2.0$: 23 communautés, $Q = 0.8903$
- $\gamma = 3.0$: 23 communautés, $Q = 0.8903$




Figure 4: Nombre de communautés détectées en fonction du paramètre γ .

Ces résultats montrent une structure multi-échelle stable :

- Pour $\gamma = 0.5$, le réseau est divisé en davantage de petites communautés (26), reflétant une sur-segmentation des ménages.

- Pour $\gamma = 1.0$, on observe le niveau de modularité maximal ($Q = 0.8930$) avec 22 communautés.
- Pour $\gamma \geq 1.5$, la partition devient remarquablement stable avec exactement 23 communautés pour trois valeurs consécutives de γ .

Cette stabilité suggère l'existence d'un niveau d'organisation modulaire intrinsèque au réseau Malawi, correspondant probablement à la structuration par ménages.

11.1 k-core decomposition

La décomposition en k -cores permet d'identifier le noyau structurel du réseau ainsi que les individus situés en périphérie. Un k -core est un sous-graphe maximal où chaque nœud possède un degré au moins égal à k .

L'analyse sur le réseau Malawi donne les résultats suivants :

- k -core maximal : **7** ;
- taille du noyau : **31 individus** ;
- taille de la périphérie ($k = 1$) : **2 individus** (nœuds 72 et 10).

Cela révèle une structure interne fortement hiérarchisée :

- le noyau (7-core) regroupe les individus les plus connectés, souvent des adultes très actifs ou des HSA (Health Surveillance Assistants), comme décrit dans l'article ;
- la périphérie est extrêmement réduite, ce qui confirme que la majorité du village participe de manière significative aux interactions sociales.

La Figure 5 illustre cette structure : les nœuds du noyau apparaissent en rouge.

Structure Core-Periphery du réseau Malawi (k-core maximal = 7)




Figure 5: Structure core-periphery du réseau Malawi (k-core maximal = 7).

Cette organisation met en évidence un **noyau social dense et robuste**, soutenu par un petit nombre d'individus centraux qui jouent un rôle clé dans la connectivité globale du réseau.

12 Dynamique épidémique

L'étude de la diffusion d'une infection dans le réseau Malawi s'appuie sur les outils vus au Chapitre 9 : valeur propre dominante, identification des *superspreaders* et simulation du modèle SIR. Toutes les analyses sont effectuées sur la **composante géante** du réseau, qui contient ici **84 nœuds**.

12.1 Seuil épidémique

Le seuil fondamental d'invasion d'une épidémie dans un réseau est donné par :

$$\frac{\beta}{\mu} > \frac{1}{\lambda_{\max}},$$

où $\lambda_{\max}$ est la plus grande valeur propre de la matrice d'adjacence.

Le calcul donne :

$$\lambda_{\max} = 11.9348, \quad \frac{1}{\lambda_{\max}} = 0.0838.$$

Ainsi, une maladie se propage dans la population si son ratio de contagiosité β/μ dépasse **0.0838**. Ce résultat signifie qu'une infection même modérément transmissible peut envahir rapidement le village, ce qui confirme la forte connectivité structurelle observée dans les étapes précédentes.

12.2 Identification des superspreaders

Les superspreaders sont identifiés via trois mesures de centralité définies sur la composante géante : centralité de degré, eigenvector centrality et distribution stationnaire de la marche aléatoire.

Les nœuds ayant les plus fortes valeurs dans ces mesures jouent un rôle d'amplificateur potentiel dans la diffusion épidémique.

Le classement obtenu est le suivant (top 10 selon la distribution stationnaire) :

Node	Degree	Eigenvector	Stationary prob.
16	31	0.257	0.0448
81	26	0.311	0.0376
69	18	0.144	0.0260
74	17	0.234	0.0246
70	16	0.224	0.0231
1	16	0.182	0.0231
52	15	0.204	0.0217
63	15	0.214	0.0217
86	15	0.137	0.0217
33	14	0.216	0.0202

Le nœud **16** apparaît comme le super-propagateur principal, cumulant haut degré, forte eigenvector centrality et probabilité stationnaire élevée. Ce résultat est cohérent avec les analyses structurales et avec l'article qui mentionne que certains adultes très actifs jouent un rôle disproportionné dans les interactions sociales.

Le nœud **67**, à l'inverse, présente les centralités les plus faibles et sert de cas extrême pour un scénario d'infection peu favorable.

12.3 Simulation SIR

Nous simulons la propagation d'une infection selon le modèle SIR avec :

$$\beta = 0.03, \quad \mu = 0.02.$$

Deux scénarios opposés sont testés :

- **Patient zéro = superspreader** (nœud 16) ;
- **Patient zéro = individu périphérique** (nœud 67).




Figure 6: Simulation SIR sur la composante géante du réseau Malawi.

Les résultats montrent une différence radicale :

- Lorsqu'un **superspreader** est infecté, l'épidémie devient rapidement massive, dépassant plus de **50 individus infectés simultanément**.
- Lorsqu'un **nœud périphérique** est infecté, la propagation reste très limitée et s'éteint rapidement.

13 Conclusion

Dans l'ensemble, l'analyse théorique (centralités, spectre, détection de communautés, k -core), les modèles aléatoires, les dynamiques fondées sur les marches aléatoires, la dynamique de consensus et les simulations SIR convergent vers une conclusion cohérente.

Le réseau Malawi apparaît comme un système social **hautement structuré**, organisé autour de **ménages fortement cohésifs** et reliés entre eux par un **noyau**

d'individus clés qui assurent la connectivité globale. Cette combinaison d'un enracinement communautaire très fort et d'un petit nombre d'acteurs centraux explique simultanément :

- la robustesse de la structure sociale locale ;
- la forte modularité observée ;
- la sensibilité du réseau à une diffusion épidémique lorsque les individus centraux sont infectés.

Ainsi, notre analyse confirme et étend les résultats de l'article du Malawi, en mobilisant l'ensemble des outils vu en cours de *Graph Mining*.