

Analyse du réseau de contacts du Malawi

Application des concepts du cours et comparaison des distributions

1 Introduction

Ce rapport présente une analyse détaillée du réseau de contacts collecté dans un village rural du Malawi à l'aide de capteurs de proximité. Ces données, enregistrées à haute résolution temporelle, permettent de reconstruire le réseau social réel d'une communauté et d'en étudier la structure interne, la dynamique sociale et les mécanismes potentiels de diffusion d'une infection.

L'objectif de ce travail est :

- comprendre la structure sociale sous-jacente du village et identifier les acteurs clés ;
- comparer nos observations quantitatives aux conclusions de l'article scientifique original.

2 Description du dataset

Les données analysées dans ce rapport proviennent d'une étude de terrain menée dans le village rural de **Mdoliro**, Malawi, où les habitants ont porté des capteurs de proximité de type RFID. Ces capteurs enregistrent automatiquement les contacts entre individus, à une résolution temporelle (secondes).

Le fichier brut disponible (`tnet_malawi_pilot.csv`) contient les colonnes suivantes :

- **id1** : identifiant du premier individu en contact ;
- **id2** : identifiant du second individu ;
- **day** : jour de la collecte (période d'observation de plusieurs jours) ;
- **contact_time** : durée du contact enregistré ;
- une colonne "*Unnamed: 0*" issue de l'export, supprimée lors du prétraitement.

Chaque ligne correspond à un *événement de contact*, et plusieurs lignes peuvent correspondre à une même paire d'individus.

Nettoyage appliqué

Afin de reconstituer un réseau cohérent et comparable à celui utilisé dans l'article :

1. suppression des lignes dont le **contact_time** est égal à 0 ;

2. agrégation des interactions entre une même paire d'individus (somme des durées cumulées) ;

Après agrégation, le graphe contient :

- **86 nœuds** ;
- **347 arêtes** ;
- Le graphe obtenu est composé de deux composantes connexes : une composante géante de 84 nœuds et une composante mineure de 2 nœuds isolés.

3 Structure générale du réseau

3.1 Construction du graphe (non pondéré)




Figure 1: Réseau de contacts du Malawi

Le réseau observé est presque entièrement connecté, ce qui suggère une communauté socialement soudée. Le **degré moyen** est de **8.07**, indiquant un niveau notable de connectivité, tandis que le **degré maximal** atteint **31**, révélant l'existence de personnes très actives socialement.

Le **coefficient de clustering**, égal à **0.5269**, constitue l'un des résultats les plus marquants. Il montre une

densité exceptionnelle de triangles, traduisant des sous-groupes fortement cohésifs, sans doute liés aux ménages.

La **distance moyenne** de **2.6153** et le **diamètre** limité à **5** indiquent une structure compact. Le réseau présente ainsi les caractéristiques typiques d'un small-world : forte densité locale et communication rapide à l'échelle globale.

4 Analyse des centralités

4.1 Betweenness Centrality

La **betweenness centrality** met en évidence les individus jouant un rôle d'intermédiaire entre différentes parties du réseau. Le nœud **16** se distingue particulièrement avec une valeur de **0.3197**, nettement supérieure à celles des nœuds 81 et 74. Il occupe une position stratégique de pont entre différentes parties du réseau.

4.2 Eigenvector Centrality

La **eigenvector centrality** identifie les individus appartenant au cœur des structures les plus connectées. Les nœuds **70**, **54**, **15**, **63** et **48** obtiennent les valeurs les plus élevées (par exemple **0.5464** pour le nœud 70).

Ils forment un noyau central où l'influence sociale est renforcée par la proximité avec d'autres individus centraux. Ces nœuds jouent un rôle d'ancrage dans la structure interne du village.

4.3 PageRank

Le **PageRank** met en évidence l'importance dynamique des individus. Le nœud **16** présente une valeur élevée de **0.02835**, suivi des nœuds **70** (**0.02410**) et **54** (**0.02026**).

Ces mesures confirment l'existence de deux types d'acteurs clés : des intermédiaires structurants et un noyau dense d'individus influents.

4.4 Closeness Centrality

La **closeness centrality** renseigne sur la proximité moyenne d'un individu avec le reste du réseau. Le nœud **16** présente une valeur de **0.5845**, ce qui confirme sa position centrale. Les nœuds **81** (**0.5389**), **74** (**0.5061**) et **86** suivent avec des valeurs élevées.

La superposition d'une **betweenness** élevée et d'une **closeness** élevée confirme que le nœud 16 joue simultanément le rôle d'intermédiaire et de centre géométrique du réseau.

5 Comparaison avec des modèles aléatoires

5.1 Modèle Erdős–Rényi

Le modèle **Erdős–Rényi** permet de mesurer dans quelle mesure la structure observée pourrait émerger du hasard. Le **clustering moyen** des graphes ER atteint seulement **0.0976**, loin du clustering réel **0.5269**. La **variance des degrés** y est également beaucoup plus faible (**7.27** contre **26.13**).

La **distance moyenne** observée dans les graphes ER est de **2.3389**, légèrement inférieure à celle du réseau réel, ce qui reflète l'absence de structure interne.

Enfin, la **modularity** obtenue dans ER est d'environ **0.292**, très éloignée de la valeur réelle **0.893**. Le réseau ne peut donc pas être assimilé à un graphe aléatoire simple.

5.2 Configuration Model

Le **Configuration Model**, qui conserve la distribution exacte des degrés, ne parvient pas davantage à reproduire les caractéristiques du réseau réel. Le **clustering** n'y atteint que **0.1393**, et la **modularity** seulement **0.3013**.

Bien que la **distance moyenne** simulée (**2.4256**) soit proche de celle du réseau réel, ces modèles restent incapables de recréer l'intensité des communautés. Cela montre que la structure observée ne provient pas des degrés, mais d'une organisation sociale réelle et forte.

6 Marche aléatoire

La marche aléatoire, qui mesure la dynamique de visite des nœuds, met en évidence les individus les plus susceptibles d'être atteints lors d'un parcours au hasard. Le nœud **16** obtient une proportion de visites de **0.046**, suivi par les nœuds 81, 86, 74 et 70.

Cela confirme que certaines personnes concentrent naturellement une part importante de la dynamique sociale, en raison de leur positionnement structurel.

L'analyse des contacts par heure met en évidence des variations significatives de l'activité sociale. Les heures **30** et **31** présentent des pics importants, avec respectivement **9217** et **9902** contacts.

Ces fluctuations suggèrent l'existence de routines collectives ou de moments de rassemblement intense, montrant que le réseau n'est pas seulement structuré spatialement, mais également temporellement.

7 Analyse communautaire

Comme l'algorithme de Louvain a déjà été présenté dans l'article d'origine, nous nous concentrons ici sur deux autres approches complémentaires.

7.1 Méthodes basées sur des marches aléatoires

Les méthodes fondées sur des marches aléatoires exploitent la manière dont un flux (d'information, d'individus) se déplace spontanément dans le réseau. Elles sont particulièrement pertinentes pour analyser la cohésion interne des groupes et la dynamique sociale du village.

Nous appliquons ici deux méthodes classiques : **Infomap** et **Walktrap**.

Infomap : partitionnement basé sur le flux d'information

Infomap repose sur la *Map Equation*, qui mesure la capacité à compresser la description d'une marche aléatoire sur le réseau. Si une marche aléatoire tend à rester longtemps dans une même communauté, alors la structure possède une organisation modulaire cohérente.

L'exécution d'Infomap sur le réseau Malawi donne :

- **10 communautés détectées**,
- tailles : [37, 13, 8, 4, 6, 5, 5, 3, 3, 2].

Cette partition montre une structure où un grand module central (37 individus) coexiste avec plusieurs petits ensembles fortement cohésifs. Cela suggère que le village ne se compose pas uniquement de ménages isolés, mais d'agrégats sociaux plus larges, où certains clusters regroupent plusieurs foyers.

Walktrap : communautés détectées via marches courtes

Walktrap s'appuie sur l'idée que des marches aléatoires courtes restent piégées dans les communautés. La méthode calcule des distances entre nœuds en comparant leurs signatures de marche aléatoire.

L'application de Walktrap donne :

- **11 communautés détectées**,
- tailles : [17, 3, 22, 3, 12, 6, 5, 8, 5, 3, 2].

Walktrap identifie des modules légèrement plus nombreux qu'Infomap, avec notamment deux communautés moyennes (17 et 22 membres) et plusieurs petits groupes correspondant à des ménages denses ou micro-communautés locales.

Cette structuration, basée sur la proximité dynamique entre individus, reflète fidèlement l'organisation sociale du village : des foyers fortement cohésifs reliés entre eux par des liens plus faibles, exactement comme décrit dans l'article original.

Comparaison des méthodes basées sur la marche aléatoire

Infomap et Walktrap produisent des résultats cohérents mais complémentaires :

- Infomap met en évidence un **macro-groupe dominant** de 37 individus, signe d'un flux social très concentré autour de certains clusters.
- Walktrap révèle une structure **méso-échelle** plus détaillée, avec 11 communautés dont plusieurs de taille moyenne (12 à 22 individus).

Ces deux méthodes contrastent avec Louvain pondéré, qui segmente davantage le réseau (22 communautés), car Louvain exploite fortement les variations de poids.

Les méthodes basées sur la marche aléatoire montrent au contraire que, d'un point de vue dynamique,

- les ménages ne sont pas des modules isolés,
- plusieurs d'entre eux fonctionnent comme des blocs sociaux plus larges,
- le village possède une structure communautaire hiérarchique, allant du ménage vers des communautés agrégées.

Ainsi, Infomap et Walktrap révèlent des caractéristiques sociales clés du réseau : la coexistence d'un noyau central très interconnecté et d'une périphérie composée de petits groupes familiaux.

8 Spectre du Laplacien et dynamique de consensus

L'analyse spectrale constitue un outil fondamental pour comprendre la structure interne d'un réseau. Elle permet d'identifier les composantes connexes, de quantifier la cohésion des communautés et d'étudier la dynamique de propagation ou de synchronisation sur le graphe. Dans cette section, nous analysons le réseau Malawi à travers trois approches complémentaires : le **spectral clustering**, le **spectre du Laplacien normalisé** et la **dynamique de consensus** $\dot{x} = -Lx$.

8.1 Spectral clustering

Nous appliquons un spectral clustering en fixant le nombre de communautés à $k = 8$, conformément au résultat obtenu avec Louvain non pondéré dans l'article de référence.

Le résultat obtenu est le suivant :

8 communautés avec tailles [41, 21, 6, 5, 5, 3, 3, 2].

Ces tailles montrent une structure modulaire cohérente : quelques communautés de taille moyenne dominent la décomposition, accompagnées de plusieurs groupes plus petits, probablement liés à des ménages ou sous-ménages.

8.2 Valeurs propres du Laplacien normalisé

Le calcul des dix plus petites valeurs propres du Laplacien normalisé donne :

$$\lambda = \begin{bmatrix} 0.000000 \\ 0.000000 \\ 0.067425 \\ 0.132788 \\ 0.147327 \\ 0.184823 \\ 0.232372 \\ 0.298524 \\ 0.312749 \\ 0.331314 \end{bmatrix}.$$

Ces résultats permettent plusieurs observations majeures :

1. **Présence de deux valeurs propres nulles.** Selon le théorème spectral du Laplacien, La présence de deux valeurs nulles indique donc que le réseau Malawi n'est pas entièrement connecté : il se compose d'une grande composante principale et d'une petite composante isolée. Cette composante secondaire regroupe des individus n'ayant enregistré aucun contact avec le reste du village, probablement parce qu'ils ont été très peu présents ou ont porté le capteur de manière incorrecte durant la période d'observation.
2. **Valeurs propres faibles ($\lambda_2, \lambda_3, \dots$).** Les valeurs proches de zéro (0.067, 0.133, 0.147) indiquent une séparation nette entre les ménages. Cela révèle une structure modulaire très forte : densité interne élevée dans les communautés, faible connectivité entre communautés.

En comparaison, l'article du Malawi rapporte également une forte modularité et une structure fortement contrainte par les ménages. L'analyse spectrale confirme rigoureusement ces observations.

8.3 Dynamique de consensus

Nous simulons la dynamique continue :

$$\dot{x} = -Lx,$$

où chaque nœud possède un état initial aléatoire. Cette dynamique modélise la convergence d'opinions, d'informations ou de comportements.




Figure 2: Dynamique de consensus sur le réseau Malawi.

L'interprétation est la suivante :

- Les courbes convergent rapidement à l'intérieur d'un ménage, ce qui reflète une **forte cohésion locale**.
- La convergence globale est beaucoup plus lente : cela correspond au fait que les liens inter-ménages sont faibles.
- Le plateau final correspond à un consensus global stable.

Ce phénomène illustre la **séparation d'échelles** décrite au Chapitre 6 : les clusters internes se stabilisent très vite, tandis que l'harmonisation entre clusters est graduelle.

9 Structure core-periphery

9.1 k-core decomposition

Dans le cas du réseau Malawi, le graphe complet comporte deux composantes connexes. Or, la décomposition en k -cores n'est pleinement interprétable que sur un graphe connexe. Pour cette raison, nous appliquons l'analyse exclusivement sur la **plus grande composante connexe (LCC)**, qui contient l'essentiel des interactions sociales du village.

La décomposition en k -cores permet d'identifier la structure interne du réseau. Un k -core est un sous-graphe maximal dans lequel chaque nœud possède un degré au moins égal à k .

L'analyse effectuée sur la LCC du réseau Malawi donne les résultats suivants :

- **k -core maximal : 7 ;**
- **taille du noyau (7-core) : 31 individus ;**

Ces résultats révèlent une structure interne fortement hiérarchisée. Le noyau (7-core) regroupe les individus les plus connectés du village, probablement des adultes actifs ou des Health Surveillance Assistants (HSA), dont le rôle social central a été souligné dans l'article scientifique.




Figure 3: Structure k -core du réseau Malawi (analyse sur la LCC, k -core maximal = 7).

Cette organisation met en évidence un **noyau social dense**. Cela confirme que le réseau Malawi est caractérisé par une forte cohésion interne, structurée autour d'un groupe central jouant un rôle crucial dans la connectivité globale et dans la propagation potentielle d'information ou d'infections.

9.2 Structure core-periphery basée sur les marches aléatoires

En complément de la décomposition en k -cores, qui repose uniquement sur le degré des nœuds, nous appliquons une méthode alternative de détection de la structure core-periphery fondée sur les marches aléatoires, telle que présentée au Chapitre 8 du syllabus.

Cette approche repose sur une interprétation dynamique de la centralité. L'idée principale est d'analyser le comportement d'un marcheur aléatoire sur le réseau : un ensemble de nœuds est considéré comme central s'il est difficile pour une marche aléatoire de le quitter.

Soit S un ensemble de nœuds. La *probabilité de persistance* α_S est définie comme la probabilité qu'un marcheur aléatoire, conditionné à être dans S à un instant donné, reste dans S au pas de temps suivant. Dans le cas d'un graphe non orienté, cette quantité s'écrit :

$$\alpha_S = \frac{\sum_{i,j \in S} A_{ij}}{\sum_{i \in S} k_i},$$

où A_{ij} est la matrice d'adjacence et k_i le degré du nœud i .

Afin d'identifier la structure core-periphery, nous utilisons un algorithme glouton. L'algorithme démarre à partir d'un nœud de degré minimal, puis ajoute itérativement le nœud qui minimise la valeur de α_S . À chaque étape, la valeur de α_S associée à l'ajout d'un nœud définit sa *coreness* α_i . Plus α_i est élevé, plus le

nœud est central du point de vue de la dynamique de marche aléatoire.

Plutôt que de fixer un seuil unique, nous considérons α comme un paramètre continu. Pour chaque valeur de $\alpha \in [0, 1]$, nous définissons la α -périphérie comme l'ensemble des nœuds satisfaisant $\alpha_i \leq \alpha$. Cette approche permet d'observer la dynamique d'absorption progressive des nœuds depuis la périphérie vers le cœur.

L'analyse réalisée sur la plus grande composante connexe (LCC), qui contient 84 nœuds, montre une augmentation progressive et régulière de la taille de la périphérie lorsque α augmente. Pour $\alpha = 0.1$, la périphérie contient 28 nœuds, tandis que le cœur regroupe les 56 nœuds restants.




Figure 4: Dynamique d'absorption de la périphérie en fonction de α sur le réseau Malawi.

Contrairement à la décomposition en k -cores, la structure obtenue par la méthode RW-based ne repose pas uniquement sur le degré des nœuds, mais sur leur rôle global dans la stabilité des trajectoires de marche aléatoire. Le cœur RW-based est ainsi plus large que le k -core maximal, ce qui suggère que la centralité dynamique dépasse la simple connectivité locale.

Cette analyse met en évidence le caractère complémentaire des deux approches : le k -core identifie les nœuds fortement connectés localement, tandis que la méthode RW-based capture une notion plus globale et dynamique de centralité au sein du réseau.

10 Dynamique épidémique

L'étude de la diffusion d'une infection dans le réseau Malawi s'appuie sur les outils vus au Chapitre 9 : valeur propre dominante, identification des *superspreaders* et simulation du modèle SIR. Toutes les analyses sont effectuées sur la **composante géante** du réseau, qui contient ici **84 nœuds**.

10.1 Seuil épidémique

Le seuil fondamental d'invasion d'une épidémie dans un réseau est donné par :

$$\frac{\beta}{\mu} > \frac{1}{\lambda_{\max}},$$

où $\lambda_{\max}$ est la plus grande valeur propre de la matrice d'adjacence.

Le calcul donne :

$$\lambda_{\max} = 11.9348, \quad \frac{1}{\lambda_{\max}} = 0.0838.$$

Ainsi, une maladie se propage dans la population si son ratio de contagiosité β/μ dépasse **0.0838**. Ce résultat signifie qu'une infection même modérément transmissible peut envahir rapidement le village, ce qui confirme la forte connectivité structurelle observée dans les étapes précédentes.

10.2 Identification des superspreaders

Les superspreaders sont identifiés via trois mesures de centralité définies sur la composante géante : centralité de degré, eigenvector centrality et distribution stationnaire de la marche aléatoire.

Les nœuds ayant les plus fortes valeurs dans ces mesures jouent un rôle d'amplificateur potentiel dans la diffusion épidémique.

Le classement obtenu est le suivant :

Node	Degree	Eigenvector	Stationary prob.
16	31	0.257	0.0448
81	26	0.311	0.0376
69	18	0.144	0.0260
74	17	0.234	0.0246
70	16	0.224	0.0231

Le nœud **16** apparaît comme le super-propagateur principal, cumulant haut degré, forte eigenvector centrality et probabilité stationnaire élevée. Ce résultat est cohérent avec les analyses structurales et avec l'article qui mentionne que certains adultes très actifs jouent un rôle disproportionné dans les interactions sociales.

10.3 Simulation SIR

Nous simulons la propagation d'une infection selon le modèle SIR avec :

$$\beta = 0.03, \quad \mu = 0.02.$$

Deux scénarios opposés sont testés :

- **Patient zéro = superspreader** (nœud 16) ;
- **Patient zéro = individu périphérique**.




Figure 5: Simulation SIR sur la composante géante du réseau Malawi.

Les résultats montrent une différence radicale :

- Lorsqu'un **superspreader** est infecté, l'épidémie devient rapidement massive, dépassant plus de **50 individus infectés simultanément**.
- Lorsqu'un **nœud périphérique** est infecté, la propagation reste très limitée et s'éteint rapidement.

11 Conclusion générale

Ce travail a permis d'analyser la structure et les dynamiques du réseau de contacts du village de Mdoliro (Malawi) en mobilisant les principaux outils du cours de *Graph Mining*.

Les analyses montrent que le réseau est fortement structuré autour de **ménages très cohésifs**, comme l'indiquent le clustering élevé, la modularité exceptionnelle et la convergence rapide observée dans la dynamique de consensus à l'échelle locale. Ces résultats confirment les conclusions de l'article scientifique de référence.

Au-delà de cette organisation locale, l'étude met en évidence l'existence d'un **noyau restreint d'individus centraux** jouant un rôle clé dans la connectivité globale du réseau. Les mesures de centralité, les méthodes de détection de communautés (*Infomap* et *Walktrap*), la décomposition en *k*-cores et l'analyse core-periphery basée sur les marches aléatoires identifient de manière cohérente ces acteurs, qui assurent la liaison entre les ménages.

La comparaison avec des modèles aléatoires montre que cette structure ne peut être expliquée ni par le hasard ni par la seule distribution des degrés, mais reflète une organisation sociale réelle et hiérarchique.

Enfin, l'analyse épidémique souligne les implications pratiques de cette structure : la présence d'individus centraux rend le réseau vulnérable à une propagation rapide des infections, comme l'illustrent les simulations SIR.

En conclusion, cette étude confirme et enrichit les résultats de l'article original en proposant une analyse à la fois structurelle et dynamique du réseau Malawi.